

Identifikasi Spesies Ikan Menggunakan *Convolutional Neural Network*

Siti Nur Hasanah ¹

¹ Department of Computer Science, Graduate School, IPB University, Bogor, Indonesia; siti.nurhasanah@apps.ipb.ac.id

Abstrak: Konsumsi ikan global terus mengalami peningkatan setiap tahunnya. Hal ini menuntut agar produksi ikan dapat memenuhi kebutuhan konsumsi ikan. Spesies tangkapan ikan memberikan informasi penting dalam pengelolaan budidaya akuakultur. Pengelolaan budidaya ikan dapat dilakukan dengan lebih baik sesuai dengan jenis spesiesnya. Beberapa organisasi internasional meminta kapal penangkap ikan untuk melaporkan spesies tangkapannya. Secara manual, proses pelaporan ini dilakukan hanya melalui pengamatan nelayan. Pengamatan secara manual ini sangat rentan terhadap kesalahan. Oleh karena itu diperlukan suatu sistem otomatis yang dapat mengidentifikasi spesies ikan dengan tepat, tanpa membutuhkan pengawasan manusia yang terlalu besar. Penelitian ini menerapkan teknik *Convolutional Neural Network* (CNN) untuk melakukan identifikasi dan klasifikasi dari sembilan jenis produk akuakultur (8 jenis ikan dan 1 jenis udang), yaitu *Black Sea Sprat*, *Gilt-Head Bream*, *Horse Mackerel*, *Red Mullet*, *Red sea Bream*, *Sea Bass*, *Striped Red Mullet*, *Trout*, dan *Shrimp*. Hasil penelitian, model CNN yang dibangun dapat memprediksi spesies ikan dengan akurasi 99,67%. Model yang digunakan pada penelitian ini sudah dapat melakukan klasifikasi citra ikan dengan baik.

Kata kunci: CNN; klasifikasi dan identifikasi ikan

Citation: Lastname, F.; Lastname, F.; Lastname, F. Title. *J. Mar. Sci. Eng.* **2021**, *9*, x. <https://doi.org/10.3390/xxx>

Academic Editor: First-name Lastname

Received: date

Accepted: date

Published: date

Publisher's Note: MDPI stays neutral with regard to jurisdictional claims in published maps and institutional affiliations.



Copyright: © 2021 by the authors. Submitted for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

1. Pendahuluan

Ikan merupakan salah satu sumber protein hewani utama yang baik untuk dikonsumsi. Produksi ikan global diperkirakan mencapai sekitar 179 juta ton pada tahun 2018, dengan total nilai penjualan diperkirakan mencapai 401 miliar dolar [1]. Organisasi Pangan dan Pertanian Perserikatan Bangsa Bangsa (FAO) mencatat bahwa konsumsi ikan global terus meningkat setiap tahunnya rata-rata 3,1% sejak tahun 1961-2017, nilai ini dua kali lebih besar dibandingkan dengan laju pertumbuhan penduduk dunia untuk periode yang sama, dan lebih tinggi dari laju konsumsi protein hewani lainnya (seperti daging, susu, dll). Karena tingginya permintaan serta semakin berkembangnya teknologi penangkapan ikan, proses penangkapan ikan dalam beberapa waktu terakhir telah dilakukan dengan sangat cepat. Namun, FAO juga melaporkan bahwa di beberapa negara telah terjadi penangkapan ikan yang berlebihan. Penangkapan ikan yang berlebihan dapat memicu munculnya berbagai masalah baru, seperti terjadinya penurunan populasi ikan, terganggunya keseimbangan ekosistem, dll.


Organisasi Internasional mulai mengatur praktik penangkapan ikan, dengan mengharuskan kapal untuk melaporkan statistik mengenai tangkapannya [2]. Proses pencatatan untuk pelaporan ini biasanya dilakukan secara manual oleh nelayan, namun tingkat keakuratan dari data yang dilaporkan secara manual ini tidak terlalu bagus. Oleh karena itu, pendekatan otomatis dibutuhkan untuk melakukan identifikasi spesies dan perhitungan ikan. Jika

dikombinasikan dengan sistem monitoring berbasis elektronik atau sistem berbasis Internet of Things (IoT), pendekatan ini dapat digunakan dalam mengidentifikasi spesies ikan yang ditangkap dari citra atau video secara otomatis. Identifikasi ikan tidak hanya terbatas untuk melakukan perhitungan dan pengenalan spesies. Namun, pada bidang akuakultur, identifikasi dan klasifikasi spesies juga berguna untuk prediksi hasil produksi, manajemen produksi, pemantauan ekosistem dan untuk mengetahui lebih rinci mengenai perilaku ikan di bawah air dari citra atau video.

Para peneliti memperkirakan terdapat lebih dari 34.000 spesies ikan yang ada di seluruh dunia, yang menghuni berbagai habitat perairan [3]. Spesies ikan diidentifikasi berdasarkan spesimennya. Spesimen ini ada yang dalam hal fitur visual seperti bentuk, tekstur, warna, ukuran, dll. Perkembangan teknologi saat ini mendukung perkembangan bidang *image analysis* dan *computer vision*. Dengan perkembangan yang cukup pesat pada kedua bidang tersebut menjadikan identifikasi spesies ikan dapat dilakukan dengan berbagai pendekatan. *Deep Learning* merupakan salah satu metode pendekatan yang banyak digunakan pada bidang *image analysis* dan *computer vision*. Model *Deep Learning* dapat mempelajari karakteristik visual unik dari spesies yang tidak sensitif terhadap perubahan dan variasi lingkungan [4]. Salah satu arsitektur *Deep Learning* yang banyak digunakan pada bidang *image analysis* dan *computer vision* adalah *Convolutional Neural Network*.

Convolutional Neural Network (CNN) pertama kali diperkenalkan oleh [5] pada tahun 1989, untuk mengenali atau mengklasifikasikan citra tulisan tangan. Sampai dengan saat ini, seiring dengan perkembangan ilmu pengetahuan dan teknologi, CNN juga mengalami perkembangan yang sangat pesat dan telah diterapkan pada berbagai tugas klasifikasi atau pengenalan pola yang lebih menantang [6]. CNN merupakan *feedforward neural network* yang mengekstrak fitur dari data dua dimensi menggunakan algoritma *back-propagation* untuk mengoptimalkan struktur jaringan dan menyesuaikan parameter yang tidak diketahui [7]. Tidak seperti proses pada *machine learning* tradisional, kekuatan dari model *deep learning* berbasis CNN ini adalah kemampuannya untuk melakukan proses ekstraksi fitur secara otomatis. Pada CNN, proses ekstraksi fitur secara manual atau ekstraksi fitur menggunakan teknik lain tidak perlu dilakukan. Metode sederhana ekstraksi fitur pada CNN yaitu fitur diekstraksi secara progresif dengan memanfaatkan lapisan *convolutional* dan *pooling layer* untuk memetakan piksel dari citra [8]. Sehingga dapat dinyatakan bahwa satu model CNN mampu melakukan tugas ekstraksi fitur serta klasifikasi.

Beberapa penelitian sebelumnya, telah menerapkan berbagai model CNN untuk melakukan identifikasi dan klasifikasi ikan dari citra ataupun video. Penelitian yang dilakukan oleh [2] mengidentifikasi spesies ikan tuna menggunakan *deep convolutional neural network*. Pada penelitian tersebut diterapkan teknik *transfer learning* dengan arsitektur VGG-16 yang dimodifikasi. Dengan menerapkan model tersebut, identifikasi ikan tuna pada penelitian [2] mampu mencapai akurasi 96,24%. Kemudian pada penelitian yang dilakukan oleh [9], identifikasi dan klasifikasi ikan dilakukan dengan menggunakan teknik hybrid yaitu kombinasi dari Gaussian mixture models dengan YOLO *deep neural network* dari dua dataset video. Hasilnya diperoleh F-scores 95,47% dan 91,2% untuk deteksi ikan, kemudian untuk klasifikasi spesies ikan diperoleh akurasi 91,46% dan 79,8%. Gambar 1 merupakan salah satu contoh arsitektur umum dari CNN yang digunakan untuk klasifikasi ikan, yang terdiri dari *convolutional layers*, *pooling layers*, dan *fully connected layers* [7].



Gambar 1. Arsitektur umum CNN untuk klasifikasi ikan

Penelitian ini akan mengimplementasikan teknik *Convolutional Neural Network* untuk mengidentifikasi spesies ikan dari citra yang dikumpulkan oleh [10]. Dengan adanya penelitian ini, diharapkan dapat menjadi salah satu acuan dalam memahami tentang klasifikasi ikan sebagai salah satu penerapan *computer vision* dan *image analysis* pada bidang akuakultur.

2. Data dan Metode Penelitian

2.1. Data Penelitian

Data yang digunakan pada penelitian ini dikumpulkan oleh [10], merupakan citra dari sembilan jenis makanan laut (delapan jenis ikan dan satu jenis udang) yang berbeda yang dikumpulkan dari pasar di Izmir, Turki untuk proyek kolaborasi Universitas dan Industri di Izmir University of Economics. Data yang dikumpulkan terdiri dari dua jenis citra yaitu citra RGB dan citra *ground truth* (GT). Pada penelitian ini yang akan digunakan hanya citra RGB dari kesembilan spesies dengan format file png. Tabel 1 merupakan informasi mengenai jumlah citra untuk setiap spesies atau jenis ikan. Gambar 2 merupakan contoh dari beberapa citra yang akan digunakan pada penelitian ini.

Table 1. Jumlah citra pada tiap spesies atau jenis ikan

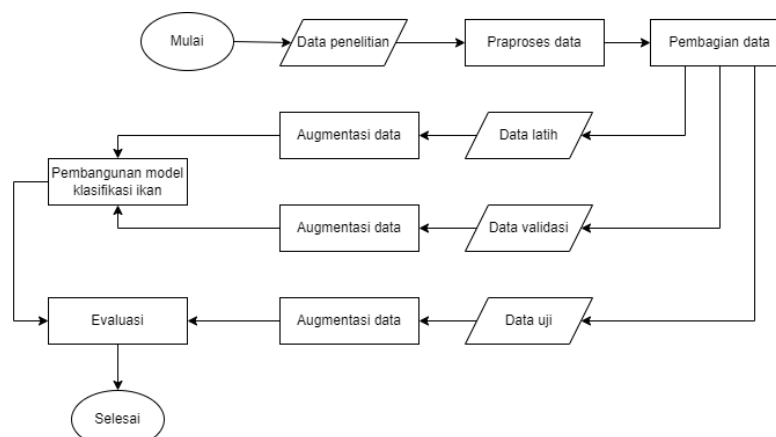
Spesies/tipe	Jumlah citra
Black Sea Sprat	1000
Gilt-Head Bream	1000
Hourse Mackerel	1000
Red Mullet	1000
Red Sea Bream	1000
Sea Bass	1000
Shrimp	1000
Striped Red Mullet	1000
Trout	1000



Gambar 2 Beberapa contoh citra ikan yang akan digunakan

2.2. Metode Penelitian

Penelitian ini terdiri dari lima tahapan utama yaitu: praproses data, pembagian data, augmentasi data, pembangunan model klasifikasi, dan evaluasi.



Gambar 3 Tahapan penelitian

2.2.1. Praproses data

Pada tahapan ini, data citra yang akan digunakan dipraproses terlebih dahulu. Tahapan praproses yang dilakukan yaitu mengubah dimensi citra yang akan digunakan menjadi $224 \times 224 \times 3$. Kemudian, nilai RGB, akan dinormalisasi dengan membagi nilai piksel 0-255 dengan 255 untuk mendapatkan nilai RGB pada rentang [0, 1].

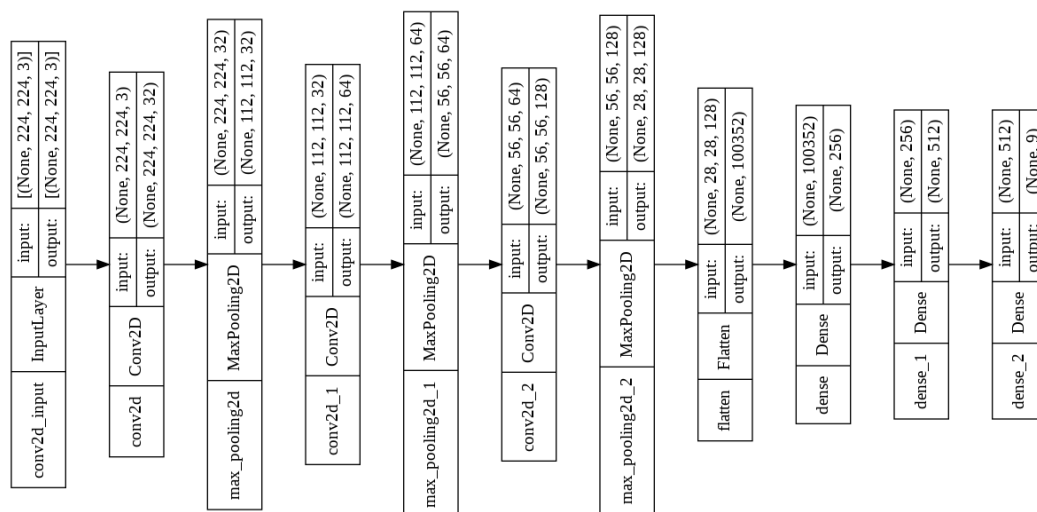
2.2.2. Pembagian data

Pembagian proporsi data citra ikan pada penelitian ini adalah sebanyak 80% untuk data latih, 10% untuk data validasi, dan 10% untuk data uji. Data latih akan digunakan untuk melakukan proses *fitting* (pembelajaran) model, data validasi akan digunakan untuk mengevaluasi model yang di-fit pada data latih agar tidak bias, dan data uji akan digunakan untuk mengevaluasi performa akhir dari model.

2.2.3. Augmentasi data

Beberapa teknik augmentasi yang telah diterapkan dalam melakukan klasifikasi citra ikan yaitu *flipping*, *width shifting*, *rotation*, *shearing*, dan *zoom* [2]. Pada penelitian ini, semua teknik augmentasi tersebut akan diterapkan pada data latih, data validasi, dan data uji. *Flipping* adalah proses untuk membalikkan citra secara horizontal dan vertikal, pada *width shifting* citra akan digeser secara acak baik ke arah kiri ataupun kanan, *rotation* adalah proses untuk memutar citra, *shearing* adalah proses menggeser satu bagian citra seperti jajar genjang yang membuat bayangan dari citra menjadi miring, *zoom* adalah proses untuk memperbesar citra. Augmentasi data ini merupakan salah satu cara yang dapat digunakan untuk menghindari terjadinya *overfitting*, karena model dapat mempelajari data yang lebih bervariasi [11]. Semua proses augmentasi akan dilakukan menggunakan kelas *ImageDataGenerator* yang tersedia pada *framework* Keras.

2.2.4. Pembangunan model klasifikasi



Gambar 4 Arsitektur dasar CNN yang akan digunakan

Gambar 4 merupakan arsitektur dasar CNN yang akan digunakan pada penelitian ini. Terdapat 3 convolutional layer, setiap sesudah satu convolutional layer terdapat satu pooling layer yang berfungsi untuk mereduksi ukuran input dengan tetap mempertahankan informasinya, kemudian terdapat sebuah flatten layer yang berfungsi untuk mengubah output multidimensional array dari proses pada layer-layer sebelumnya menjadi array satu dimensi (vektor) agar dapat digunakan sebagai input pada fully-connected layer, berikutnya terdapat dua fully-connected (dense) layer, dan terakhir layer output yang terdiri dari sembilan node sesuai dengan jumlah spesies ikan yang akan diklasifikasi. Convolutional dan pooling layer adalah layer dari CNN yang berfungsi untuk melakukan ekstraksi fitur atau ciri dari citra yang akan diklasifikasikan. Kemudian fully connected layer berfungsi untuk melakukan klasifikasi dari citra input.

2.2.5. Evaluasi

Kemampuan model dalam melakukan klasifikasi ikan pada penelitian ini akan dilihat confusion matrix dari hasil prediksi. Confusion matrix adalah sebuah tabel yang merepresentasikan informasi mengenai nilai aktual dan prediksi dari sebuah sistem klasifikasi. Tabel 2 merupakan gambaran confusion matrix yang memiliki nilai aktual dan prediksi untuk kasus klasifikasi biner, pada kasus ini yaitu kelas positif dan negatif.

Table 2 Confusion Matrix

		Prediksi	
		Positif	Negatif
Aktual	Positif	<i>True positive</i>	<i>False negative</i>
	Negatif	<i>False positive</i>	<i>True negative</i>

dengan true positive (TP) adalah jumlah kasus positif yang teridentifikasi dengan benar, false positive (FP) adalah jumlah kasus negatif yang teridentifikasi sebagai kasus positif, *false negative* (FN) adalah jumlah kasus positif yang teridentifikasi negatif, dan true negative (TN) adalah jumlah kasus negatif yang teridentifikasi dengan benar.

Kemudian dari *confusion matrix* akan dihitung nilai akurasi model. Akurasi adalah nilai yang menunjukkan seberapa banyak hasil prediksi yang sesuai dengan nilai aktual [12]. Akurasi dihitung berdasarkan persamaan (1) berikut:

$$Akurasi = \frac{TP + TN}{TP + FP + TN + FN}$$

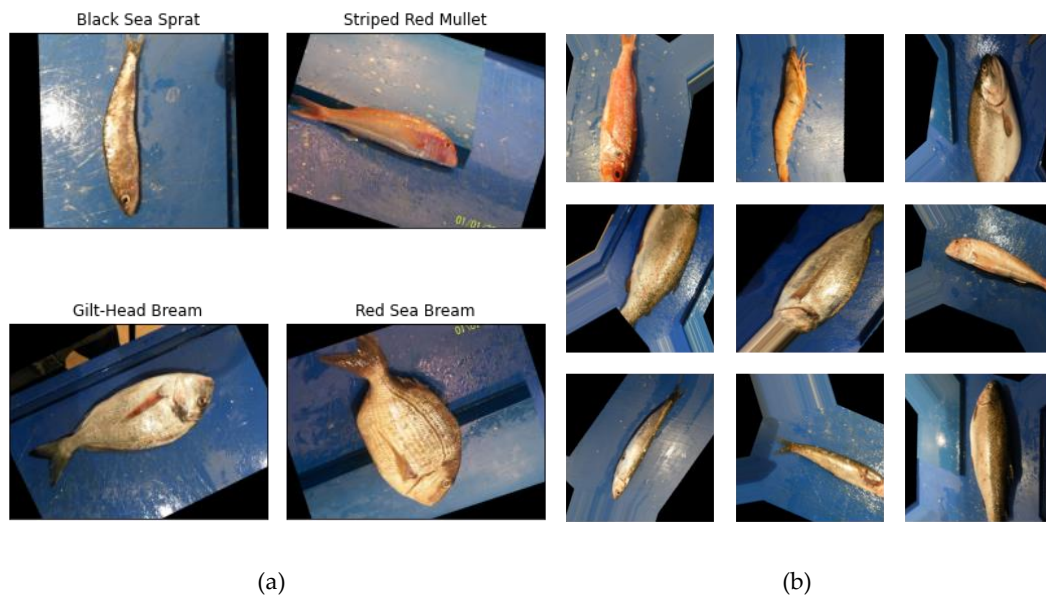
3. Hasil dan Pembahasan

Sebelum dilakukan proses pemodelan klasifikasi ikan menggunakan CNN, data citra melalui serangkaian tahapan, mulai dari praproses, pembagian data, serta augmentasi data. Citra ikan yang telah diproses dibagi menjadi data latih, data validasi, dan data uji dengan perbandingan 80:10:10. Proporsi setiap spesies ikan pada data latih, data validasi, dan data uji dapat dilihat pada Tabel 3.

Table 3 Proporsi data setelah dilakukan pembagian data

Label	Data latih	Data validasi	Data uji
Black Sea Sprat	808	89	103
Gilt-Head Bream	807	94	99
Horse Mackerel	783	117	100
Red Mullet	785	118	97
Red Sea Bream	814	87	99
Sea Bass	799	87	114
Shrimp	807	93	100
Striped Red Mullet	807	99	94
Trout	790	116	94
Total	7200	900	900

Setelah dilakukan proses pembagian data, berikutnya dilakukan augmentasi data. Salah satu contoh hasil dari proses augmentasi data dapat dilihat pada Gambar 5 (b). Terlihat bahwa proses augmentasi yang dilakukan telah menambah variasi dari data yang ada. Beberapa citra ikan terlihat ada yang dirotasi, diperbesar, dsb.



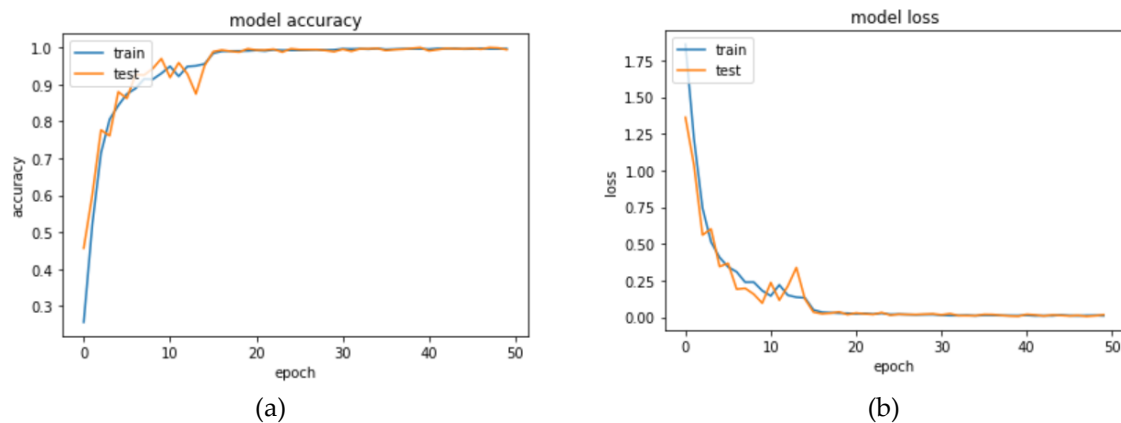
Gambar 5 (a) Contoh citra asli (b) Contoh citra setelah dilakukan augmentasi data

Setelah tahapan augmentasi data dilakukan, berikutnya data dapat digunakan sebagai input untuk model klasifikasi menggunakan *deep learning*. Pada penelitian ini, model akan dilatih selama 50 epochs. Dalam mengontrol proses yang terjadi pada saat model mempelajari data latih, maka juga diterapkan callbacks. Ada beberapa fungsi callbacks yang digunakan, yaitu EarlyStopping, ReduceLROnPlateau, dan ModelCheckpoint. EarlyStopping adalah fungsi yang akan menghentikan proses pelatihan apabila suatu kondisi telah dicapai, pada penelitian ini proses pelatihan akan berhenti apabila selama 10 epochs nilai validation loss tidak berkurang. ReduceLROnPlateau adalah fungsi yang akan mengurangi nilai *learning rate* ketika suatu metrik tidak mengalami perbaikan, pada penelitian ini learning rate akan berkurang 10% apabila selama 5 epochs nilai validation_loss tidak berkurang. ModelCheckpoint adalah fungsi yang digunakan untuk menyimpan model versi terbaik selama proses training.

Model klasifikasi pertama menggunakan optimizer Adam, dengan arsitektur lebih rincinya sebagai berikut:

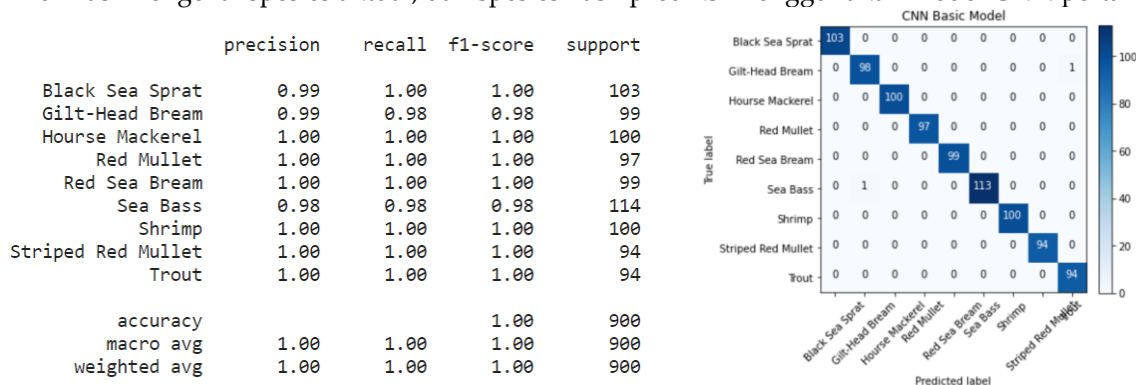
- *Convolutional layer* (32 filter, ukuran 3x3) + ReLu, *Max Pooling*
- *Convolutional layer* (64 filter, ukuran 3x3) + ReLu, *Max Pooling*
- *Convolutional layer* (128 filter, ukuran 3x3) + ReLu, *Max Pooling*
- *Dense layer* (256 unit) + ReLu
- *Dense layer* (512 unit) + reLu
- *Output layer* (9 unit) + Softmax

Gambar 6 merupakan nilai akurasi dan loss dari model selama proses pelatihan. Nilai akurasi dan loss pada data latih dan data validasi hampir sama. Hal ini mengindikasikan bahwa pada model ini tidak terjadi *overfitting*. Pada sekitar epochs ke-20 nilai akurasi pada data latih dan data uji sama-sama sudah mencapai 99%.

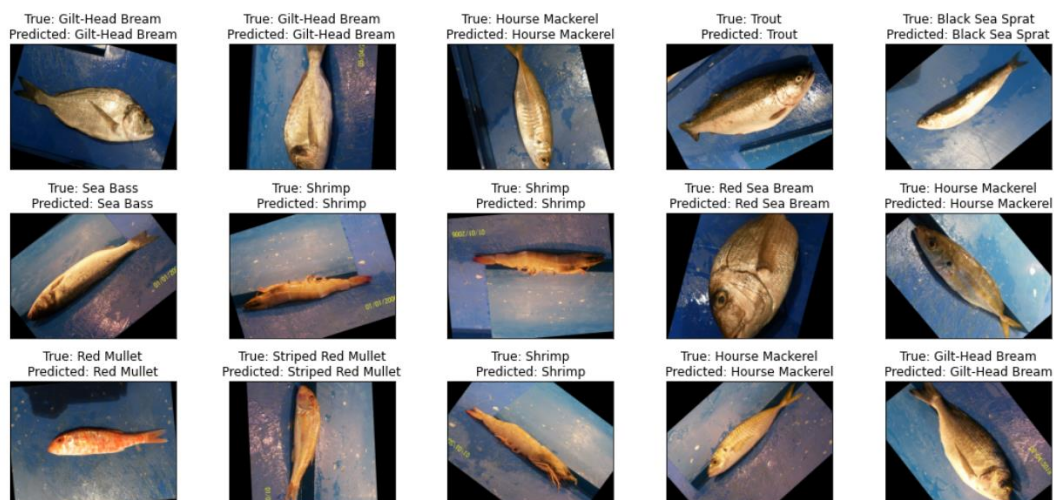


Gambar 6 (a) Akurasi model, (b) loss model selama proses pelatihan

Setelah model mempelajari data pada proses pelatihan, berikutnya model akan dievaluasi menggunakan data uji. Gambar 7 merupakan confusion matrix dari model ketika dilakukan evaluasi terhadap data uji. Model dapat melakukan klasifikasi spesies ikan dengan akurasi 99,67%. Hampir semua data dapat diklasifikasikan ke dalam kelas yang tepat. Hanya ada satu kesalahan prediksi yaitu, citra ikan *sea bass* diprediksi sebagai ikan *glit head bream*. Pada Gambar 8 terdapat beberapa contoh citra ikan yang dilengkapi dengan informasi mengenai spesies aktual, dan spesies hasil prediksi menggunakan model CNN pertama.



Gambar 7 Confusion Matrix model CNN



Gambar 8 Hasil prediksi spesies ikan menggunakan model CNN

4. Kesimpulan

Model identifikasi dan klasifikasi ikan yang digunakan pada penelitian ini mampu mengenali citra ikan dengan akurasi 99,67%. Model ini cocok digunakan untuk melakukan tugas klasifikasi pada data citra ikan yang telah dikumpulkan ini.

Namun, pada penelitian ini data citra yang digunakan merupakan citra ikan tangkapan yang sudah di atas air. Pada penelitian berikutnya, model yang dihasilkan disini dapat diuji menggunakan data citra ikan di dalam air. Penelitian yang dilakukan ini masih terbatas pada model dasar CNN. Untuk penelitian berikutnya, tingkat akurasi dari model prediksi menggunakan CNN dapat ditingkatkan dengan menerapkan beberapa teknik, misalnya dengan menggunakan teknik *transfer learning*, atau dengan melakukan *hyperparameter tuning*. Dataset yang digunakan pada penelitian dapat lebih beragam.

5. Daftar Pustaka

- [1] FAO, *The State of World Fisheries and Aquaculture*, vol. 32, no. 6. 2020.
- [2] Y. C. Lu, C. Tung, and Y. F. Kuo, "Identifying the species of harvested tuna and billfish using deep convolutional neural networks," *ICES J. Mar. Sci.*, vol. 77, no. 4, pp. 1318–1329, 2020, doi: 10.1093/icesjms/fsz089.
- [3] M. Cohut, "Researchers find over 40 new species of fish in one lake," *Medical News Today*, 2019. <https://www.medicalnewstoday.com/articles/327261> (accessed Nov. 30, 2021).
- [4] X. Yang, S. Zhang, J. Liu, Q. Gao, S. Dong, and C. Zhou, "Deep learning for smart fish farming: applications, opportunities and challenges," *Rev. Aquac.*, vol. 13, no. 1, pp. 66–90, 2021, doi: 10.1111/raq.12464.
- [5] Y. LeCun *et al.*, "Backpropagation applied to digit recognition," *Neural computation*, vol. 1, no. 4, pp. 541–551, 1989, [Online]. Available: <https://www.ics.uci.edu/~welling/teaching/273ASpring09/lecun-89e.pdf>.
- [6] M. D. Zeiler and R. Fergus, "Visualizing and understanding convolutional networks," *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 8689 LNCS, no. PART 1, pp. 818–833, 2014, doi: 10.1007/978-3-319-10590-1_53.
- [7] M. Sun, X. Yang, and Y. Xie, "Deep Learning in Aquaculture: A Review," *J. Comput.*, vol. 31, no. 1, pp. 294–319, 2020, doi: 10.3966/199115992020023101028.
- [8] H. T. Rauf, M. I. U. Lali, S. Zahoor, S. Z. H. Shah, A. U. Rehman, and S. A. C. Bukhari, "Visual features based automated identification of fish species using deep convolutional neural networks," *Comput. Electron. Agric.*, vol. 167, no. July, p. 105075, 2019, doi: 10.1016/j.compag.2019.105075.
- [9] A. Jalal, A. Salman, A. Mian, M. Shortis, and F. Shafait, "Fish detection and species classification in underwater environments using deep learning with temporal information," *Ecol. Inform.*, vol. 57, no. March, p. 101088, 2020, doi: 10.1016/j.ecoinf.2020.101088.
- [10] O. Ulucan, D. Karakaya, and M. Turkan, "A Large-Scale Dataset for Fish Segmentation and Classification," *Proc. - 2020 Innov. Intell. Syst. Appl. Conf. ASYU 2020*, 2020, doi: 10.1109/ASYU50717.2020.9259867.
- [11] R. Poojary, R. Raina, and A. K. Mondal, "Effect of data-augmentation on fine-tuned cnn model performance," *IAES Int. J. Artif. Intell.*, vol. 10, no. 1, pp. 84–92, 2021, doi: 10.11591/ijai.v10.i1.pp84-92.
- [12] S. Yildirim, "How to Best Evaluate a Classification Model," *Towards Data Science*, 2020. <https://towardsdatascience.com/how-to-best-evaluate-a-classification-model-2edb12bcc587> (accessed Nov. 30, 2021).